

珠寶購買預測

機器學習流程建構與模型效能比較

Jewelry Purchase Prediction Using Machine Learning
Pipeline Design & Model Evaluation

目的

預測可能購買珠寶的顧客族群，找出最具成長潛力的客群區隔 (Segment)，協助公司優化精準行銷策略。

組員：周季諭 | 指導老師：張志勇、廖文華、蒯思齊 | 時間：2026 年 2 月 22 日

研究背景與學習動機

背景 (Background)

- ▶ 珠寶產業從業人員，專注於顧客銷售與市場分析
- ▶ 擁有 GIA 鑑定師執照，具備寶石鑑定與價值評估專業
- ▶ 長期觀察高單價商品之顧客決策行為與消費模式

學習動機 (Motivation)

- ▶ 希望將產業經驗結合機器學習技術
- ▶ 探索如何以數據預測高價值顧客族群
- ▶ 建立從資料處理到模型評估的完整流程能力

專案目標 (Goal)

- ▶ 將珠寶顧客交易資料轉化為可預測購買行為的分類模型
- ▶ 比較不同機器學習模型的效能與應用價值

相關研究與方法選擇

傳統機器學習方法

- ▶ Logistic Regression
- ▶ Decision Tree
- ▶ Random Forest

適用於結構化資料 (Tabular Data)，具備良好可解釋性與穩定預測能力。

神經網絡方法

- ▶ Multi-Layer Perceptron (MLP)
- 可捕捉非線性關係，用於比較模型進階表現。

本研究定位

- ▶ 任務：二元分類 (是否為珠寶購買者)
- ▶ 建立完整 Machine Learning Pipeline
- ▶ 比較 LR、DT、RF 與 MLP 之預測效能
- ▶ 綜合評估準確率與模型可解釋性

專案架構與資料流程

專案檔案結構 (Project Structure)

- ▶ 01_Data_Preprocessing.ipynb —清理 Kaggle 原始資料，建立 jewelry flag
- ▶ 02_Jewelry_Model.ipynb —建立與比較多種模型 (LR / DT / RF / MLP)
- ▶ 02_Supervised_Learning_Planning.md —專案規劃與進度管理

資料流程 (Data Flow)

- ▶ Raw Data (Kaggle)
- ▶ Preprocessing (清理 + jewelry flag)
- ▶ Feature Table / Processed CSVs (建模資料表)
- ▶ Train/Test Split (X_{train} , X_{test} , y_{train} , y_{test})
- ▶ Model Training & Evaluation (LR / DT / RF / MLP)
- ▶ Business Insight (行銷與商品策略應用)

完整流程確保資料一致性與模型評估公平性 (避免資料洩漏)

資料前處理與資料摘要

珠寶業務數據（縮放後）


原始 Kaggle 價格欄位為縮放數值，本研究參考競賽討論區推論比例進行還原估計。

核心指標


- ▶ 交易數：40,724 筆 客戶數：35,592 人
- ▶ 總營收：\$267,402.71
- ▶ 中位數訂單：\$6.99

衍生指標

- ▶ 平均每客戶：\$7.51
- ▶ 平均每筆交易：\$6.57
- ▶ 平均購買次數：1.14 次/客戶
 - Avg/Customer > Avg/Txn (\$7.51 vs \$6.57) → 重複購買跡象。
 - 低頻品類 → 需以購買傾向模型精準鎖定高潛力客群。




珠寶購買率




珠寶購買者僅佔全體顧客的 2.6%

客群年齡結構比較



珠寶購買者偏向年輕，在 20-29 歲達到高峰

年齡差異是否顯著？



珠寶購買者平均年輕 3.3 歲 ($p < 0.05$ ，具統計顯著性)

目標定義與問題設定 (Target & Problem Setup)

研究目標

- ▶ 建立二元分類模型 (**Binary Classification**)，預測顧客是否為珠寶購買者

目標變數 (Target Variable)

- ▶ $y = \text{is_jewelry_buyer}$
- ▶ 1 = 珠寶購買者 (Positive Class)
- ▶ 0 = 非珠寶購買者 (Negative Class)

時間設計與建模前提

- ▶ 僅使用預測時點可取得特徵 (避免資料洩漏)
- ▶ 確保模型評估具部署可行性

特徵工程 (Feature Engineering)

特徵架構設計

- ▶ 人口統計 (**Demographics**)
年齡、會員狀態、電子報訂閱
→ 捕捉顧客基礎輪廓與行銷接觸程度
- ▶ 行為訊號 (**Behavioral Signals**)
購買頻率、消費金額、最近購買時間
→ 反映顧客活躍度與購買傾向 (RFM 概念)
- ▶ 珠寶購買歷史 (**Jewelry History**)
過去珠寶購買次數、商品多樣性
→ 衡量品類偏好與潛在忠誠度

設計原則 (**Model-Oriented Principles**)

- ▶ 僅使用預測時可取得之特徵 (Feature Availability)
- ▶ 兼顧模型可解釋性與穩定性
- ▶ 避免使用購買後才存在之資訊 (Data Leakage Prevention)

機器學習建模流程總覽 (ML Pipeline Overview)

Raw Data (Kaggle 原始資料)



Merge Datasets (資料整併)



Target Label : `is_jewelry_buyer`



Feature Engineering (特徵工程)



Feature Selection (特徵篩選)



Encoding → Split → Imputation



Final Dataset : $X_{train}, X_{test}, y_{train}, y_{test}$

資料完整性與模型控制層 (Data Integrity Modeling Controls)

模型控制機制 (Modeling Controls)

- ▶ 類別不平衡意識 (Class Imbalance Awareness)

Jewelry Buyers 僅 2.6

- ▶ 資料洩漏防範 (No Data Leakage)

缺失值填補器 (Imputer 僅於訓練集擬合 (Fit on Train Only)

移除 jewelry_avg_price 等未來資訊

- ▶ 穩健缺失值策略 (Robust Missing Strategy)

高缺失欄位刪除 (FN、Active)

類別變數 dummy_na=True

數值變數 Median Imputation

模型建構成果 (Modeling Outcome)

- ▶ 最終資料無缺失值

- ▶ 建立可重現、可部署之建模流程

基準模型：邏輯迴歸（Baseline — Logistic Regression）

Why — 為什麼選擇此模型？

- ▶ 作為可解釋且穩定的基準模型（Baseline Model）
- ▶ 提供清晰的線性決策邊界與機率輸出

What it gives — 模型帶來的價值

- ▶ 可解釋性（**Interpretability**）：每個特徵對購買機率的影響方向清楚
- ▶ 決策透明度（**Transparency**）：易於與商業邏輯對齊

What I learned — 實際觀察

- ▶ 在類別不平衡下，Accuracy 可能被高估
- ▶ ROC-AUC 表現穩定，作為後續模型比較的參考基準

可解釋模型：決策樹（Explainable — Decision Tree）

Why — 為什麼引入決策樹？

- ▶ 建立可視化決策路徑（Visual Decision Paths）
- ▶ 驗證是否存在明確的規則型購買模式

What it gives — 模型帶來的價值

- ▶ 特徵重要性（**Feature Importance**）：量化影響購買傾向的關鍵變數
- ▶ 規則解釋（**Rule-Based Reasoning**）：if-then 邏輯易於業務溝通

What I learned — 實際觀察

- ▶ 年齡與行為特徵對分類影響顯著
- ▶ 單一決策樹容易過擬合，需要更穩定模型補強

隨機森林與神經網路 (Random Forest & Neural Network)

Why — 為什麼使用高效能模型？

- ▶ 捕捉非線性關係 (Non-linear Patterns)
- ▶ 提升預測準確度與泛化能力

What it gives — 模型帶來的價值

- ▶ 隨機森林 (**Random Forest**)：穩定性高、降低過擬合風險
- ▶ 神經網路 (**MLP**)：高容量模型，能捕捉複雜交互作用

What I learned — 實際觀察

- ▶ 在測試集上 ROC-AUC 表現最佳
- ▶ 需在效能與可解釋性之間做策略取捨

模型決策分析 (Model Selection — Decision-Oriented Evaluation)

評估設定

- ▶ 使用 **Hold-out Test Set (30% Stratified Split)**
- ▶ Jewelry Buyers 僅 2.6%，存在類別不平衡
- ▶ 評估指標包含：Accuracy、Precision、Recall、F1-score、ROC-AUC
- ▶ 主要決策依據為 **ROC-AUC** 與 **Recall**（不平衡資料下較具意義）

測試集表現比較 (Test Set Performance)

模型	Accuracy	Precision	Recall	F1-score	ROC-AUC
邏輯迴歸	0.9709	0.3212	0.9994	0.4861	0.9945
決策樹	0.9710	0.3210	0.9973	0.4857	0.9945
隨機森林	0.9711	0.3223	1.0000	0.4875	0.9950
神經網路 (MLP)	0.9709	0.3212	0.9994	0.4861	0.9950

模型評估視角：ROC-AUC vs Precision-Recall

ROC-AUC（區分能力）

- ▶ 衡量模型整體排序能力
- ▶ 不依賴單一決策門檻（Threshold-Free）
- ▶ 適合評估模型整體穩定性

適用情境

- ▶ 比較不同模型
- ▶ 評估模型是否具備預測價值

Precision-Recall（決策取捨）

- ▶ Precision：預測為買家的準確比例
- ▶ Recall：成功抓到的買家比例
- ▶ 反映實際行銷成本與營收風險

適用情境

- ▶ 決定投放門檻
- ▶ 平衡誤判成本與漏判成本

決策思維

ROC-AUC 衡量模型「能力」，Precision-Recall 決定「商業策略」。

最終模型選擇 (Final Model Decision)

隨機森林 (Random Forest)

- ▶ 在不平衡資料下表現穩定
- ▶ 可提供特徵重要度 (Feature Importance)
- ▶ 過擬合風險低於神經網路

商業取捨分析 (Business Trade-off Interpretation)

- ▶ Recall ≈ 1.0 ：幾乎不漏掉高意圖顧客
- ▶ Precision ≈ 0.32 ：可接受的行銷誤觸率

決策思維 (Decision Insight)

- ▶ 在高意圖顧客預測情境下，
- ▶ 「避免漏掉潛在買家」比「減少誤判非買家」更重要
- ▶ 因此選擇 Recall 穩定且可解釋的模型

結論

- ▶ 隨機森林為本專案最佳平衡模型 (Performance + Interpretability)

決策總結 (Executive Summary)

模型成果

- ▶ ROC-AUC = 0.995 (強區分能力)
- ▶ Recall $\approx$ 1.0 (幾乎不漏掉買家)
- ▶ 隨機森林為最佳平衡模型

商業影響

- ▶ 精準識別 2.6% 高潛力客群
- ▶ 提升行銷資源配置效率
- ▶ 降低盲目投放與機會成本

下一步

- ▶ 調整預測門檻 (Threshold Optimization)
- ▶ 進行 A/B 測試驗證實際 ROI
- ▶ 建立持續監控與模型更新機制

核心觀點

本模型不僅提供預測能力，更建立可持續優化的精準行銷決策框架。


附錄 A—Dataset & Target

項目	說明
總樣本數 (Total Samples)	821,329 筆客戶紀錄
訓練集 (Training Set)	574,930 (70%)
測試集 (Test Set)	246,399 (30%)
資料切分方式 (Split Strategy)	分層隨機抽樣 (Stratified Random Sampling)
Class 0 (非珠寶購買者)	810,033 (98.6%)
Class 1 (珠寶購買者)	11,296 (1.4%)
類別不平衡比例	約 70:1 (高度不平衡)
目標變數 (Target Variable)	是否於下一次交易購買珠寶 (Binary Classification)
標籤定義	0 = 非珠寶購買者 ; 1 = 珠寶購買者

Evaluation Metric: ROC-AUC (適用於高度不平衡資料)

Data Source: 02_Jewelry_Model.ipynb

Appendix B — ROC Curve Comparison



模型 Model	AUC
邏輯迴歸 Logistic Regression	0.9945
決策樹 Decision Tree	0.9945
隨機森林 Random Forest	0.9950
神經網路 Neural Network	0.9950

測試集結果

Test Set Results